

# Redes neuronales para soportar la toma de decisiones

Ricardo Arturo Yancos Cermeño  
Universidad Galileo, Guatemala

## Introducción

Las redes neuronales son útiles para problemas de clasificación y de regresión debido a que tienen particular capacidad de aproximar funciones distintas debido sus funciones de activación y la interconectividad entre sus neuronas. Debido a esto son particularmente buenas para crear modelos matemáticos que se apeguen a los datos que reciben.

Debido a su naturaleza las redes neuronales feedforward pueden usarse muy bien para datos estructurados. Las redes recurrentes pueden aplicarse a data textual. Las redes convolucionales se prestan para clasificación de imágenes.

Se utilizaron los tres tipos de redes neuronales anteriormente mencionadas para trabajar con un dataset estructurado de diagnostico de diabetes, un dataset de imágenes de fundus para diagnostico de distintas enfermedades y un dataset con el texto de distintos tweets para detectar depresión; respectivamente.

Los modelos matemáticos resultantes pueden usarse mas tarde para soportar la toma de decisiones o realizar predicciones al presentarles nuevos datos.

## Metodología

Se seleccionaron los respectivos modelos adecuados para cada tipo de dataset. Para cada uno de estos modelos se procedió a reservar una subconjunto para prueba y el resto para entrenamiento y validación.

Debido a la naturaleza de alto costo computacional para entrenar estos modelos, se necesito entrenar diferentes variantes y arquitecturas con pocas épocas, con el fin de determinar que posibles variantes o arquitecturas poseen el mejor potencial.

Para definir el potencial se utilizan las métricas de accuracy y de precisión, puesto que además de una alta tasa de predicciones correctas también se desea una alta tasa una buena tasa de verdaderos positivos y una baja tasa de falsos positivos para evitar malos diagnósticos.

Table 1: Red neuronal feedforward

Capas ocultas	Red		Entrenamiento		Prueba	
	Tipo, neuronas, activación		Accuracy	Precision	Accuracy	Precision
1	Densa, 210, ReLU		0.8528	0.8584	0.8456	0.8489
3	Densa, 512, ReLU Densa, 256, ReLU Densa, 128, Tanh		0.8543	0.8594	0.8454	0.8496
1	Densa, 210, Tanh		0.8499	0.8556	0.8395	0.8521
3	Densa, 512, ReLU Densa, 256, ReLU Densa, 128, ReLU		0.8554	0.8599	0.8442	0.8491

Después de elegir el modelo con mayor potencial para cada uno de los tres datasets mencionados, se procedió a entrenar los modelos finales con una cantidad mas alta de épocas.

El modelo de redes convolucionales resulto ser demasiado costoso para entrenar en una computadora personal, por lo que fue necesario utilizar Google Colab para instanciar una sesión de Python con Keras capaz de utilizar un GPU (K80) para acelerar el entrenamiento.

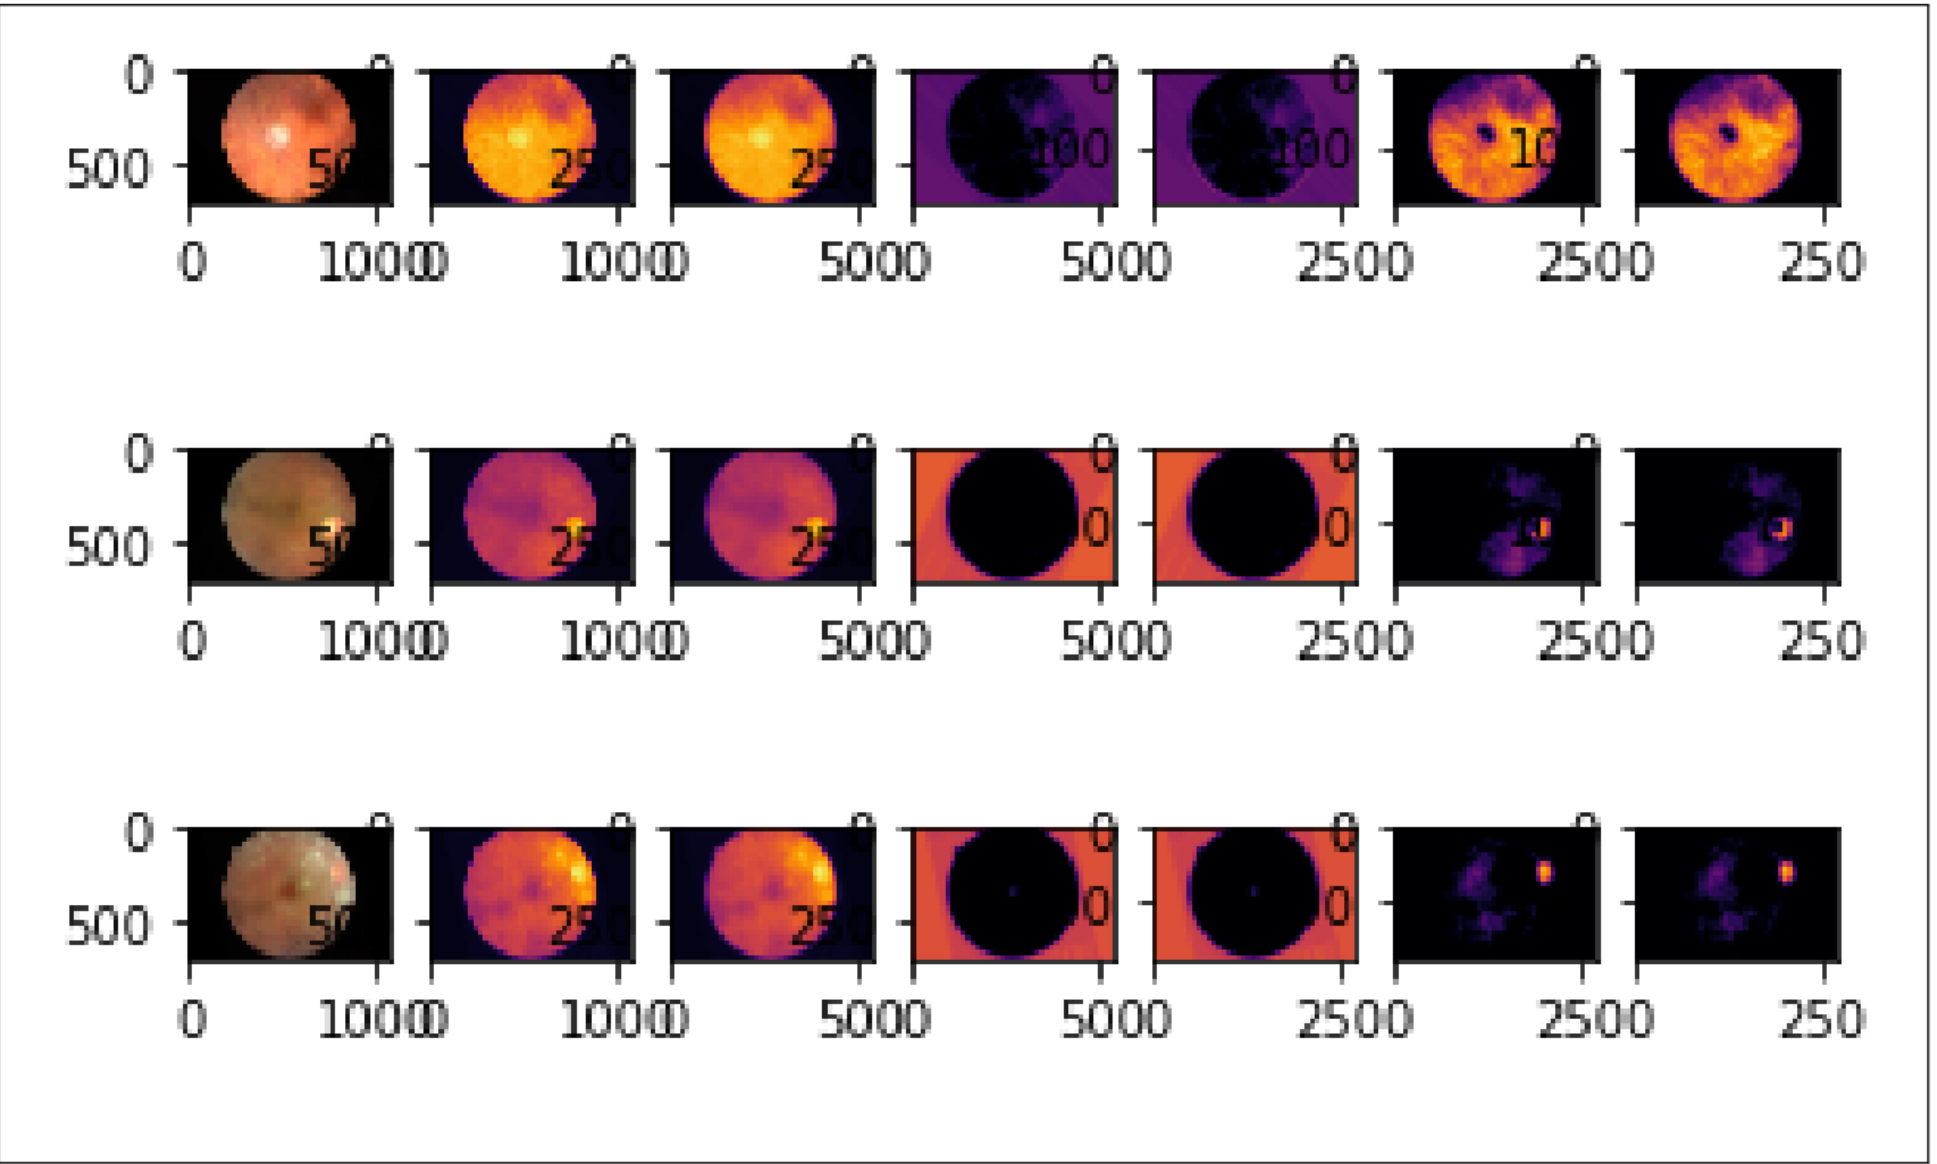


Figure 1: Algunas activaciones convolucionales

Se utilizaron callbacks para poder mantener el mejor modelo entrenado de entre todas las épocas, utilizando el accuracy como la métrica objetivo a maximizar.

Los modelos se cargaron a un servidor con Python como backend para poder realizar diagnósticos fácilmente a través de un navegador web.

## Resultados

Lla red neuronal recurrente obtuvo un accuracy de 0.86, mientras que la red neuronal feedforward alcanzo un accuracy de 0.86. La red neuronal convolucional por su parte únicamente alcanzo un accuracy de 0.29.

Se logro crear un API capaz de dar predicciones de los modelos

```
Curl
curl -X 'POST' \
  https://35.246.214.144/model/depression/ \
  -H 'accept: application/json' \
  -H 'Content-Type: application/json' \
  -d '{
    "tweet": "I am very sad"
  }'

Request URL
https://35.246.214.144/model/depression

Server response
Code    Details
200
Response body
{
  "diagnostic": "depression",
  "correcto": 0,
  "precision": 0
}
```

## Conclusión

La red feedforward y la red recurrente dieron resultados altamente prometedores, mientras que la red convolucional no fue particularmente buena.

Sin embargo, mas allá de demostrar la capacidad de los modelos matemáticos generados por las redes, se logro demostrar que es enteramente posible acelerar la toma de decisiones, aun sin un medico especialista, en cuanto al cuidado de salud.

Para una mejor implementación se debe analizar la escasez particular de médicos capaces de diagnósticos y ofrecer modelos personalizados para cubrir las brechas generadas por dicha escasez.