
Redes Neuronales

Ricardo A. Yancos*

Instituto en Investigación de Operaciones
Universidad Galileo
Guatemala, Guatemala

Abstract

Debido a la potencial demanda alta de especialistas capaces de realizar diagnósticos y su potencial escasez, el desarrollo de sistemas de soporte de toma de decisiones pueden resultar útiles para expedir la toma de acción preventiva mientras se espera a que un especialista debidamente licenciado realice un diagnóstico oficial, por eso se presenta en este reporte los resultados de entrenar tres tipos de redes neuronales sobre datasets relacionados a el diagnóstico de distintos padecimientos, como prueba de concepto para proponer redes neuronales, junto con otras técnicas de machine learning o inteligencia artificial, como potenciales herramientas de soporte de toma de decisiones.

1 Introducción

Existen distintos tipos de datos, como estructurados o no estructurados, aquellos donde importa el orden o no, donde el contexto espacial de un dato es importante o no. Por este motivo es que existen distintas maneras de enfrentar los problemas según las condiciones de los datos.

Una red neuronal feedforward es bastante útil para problemas bien estructurados donde no importa la temporalidad o la espacialidad en el dataset, pues tiene la ventaja de que puede simular cualquier tipo de función gracias a las distintas funciones de activación en las capas ocultas y la interconectividad de sus neuronas, sin embargo pierde eficacia cuando los datos no están bien estructurados, como imágenes o texto natural. En caso de datos donde importa la temporalidad y el orden, como texto, pueden usarse redes neuronales recurrentes, las cuales cuentan con feedback junto con feedforward para poder apreciar la secuencia o temporalidad en los datos analizados, permitiendo aprender patrones en datos que dependen del contexto (o datos que le rodean). Por otra parte, una red neuronal convolucional consiste en dejar que se creen kernels, o filtros, que aprenden a detectar ciertas características en un conjunto de datos donde importa la espacialidad, como una imagen, permitiendo identificar cosas tan sencillas como círculos o líneas rectas hasta patrones más complejos, como caras.

Los datos médicos que se logran recopilar usualmente ocupan los tres tipos de datos descritos anteriormente, como imágenes resultados de algún examen de laboratorio o resultados de un cuestionario médico. Para este proyecto, se utiliza un conjunto de datos estructurado, uno de texto y uno de imágenes, por lo que se usaron los tres tipos de redes neuronales descritas anteriormente.

2 Metodología

Se utiliza la implementación en Python del API de Keras para poder entrenar tres distintas redes neuronales, una feedforward, una recurrente y una convolucional. El API de Keras permite abstraer el uso de TensorFlow 2 para el entrenamiento de distintos tipos de modelos de machine learning y

*16004971@galileo.edu

Table 1: Red neuronal feedforward

Capas ocultas	Red	Entrenamiento		Prueba	
	Tipo, neuronas, activación	Accuracy	Precision	Accuracy	Precision
1	Densa, 210, ReLU	0.8528	0.8584	0.8456	0.8489
3	Densa, 512, ReLU	0.8543	0.8594	0.8454	0.8496
	Densa, 256, ReLU				
	Densa, 128, Tanh				
1	Densa, 210, Tanh	0.8499	0.8556	0.8395	0.8521
3	Densa, 512, ReLU	0.8554	0.8599	0.8442	0.8491
	Densa, 256, ReLU				
	Densa, 128, ReLU				

deep learning, por lo cual facilita el trabajo necesario para definir redes neuronales y evaluarlas en distintos conjuntos de datos.

La la red neuronal feedforward se decidio trabajar con un conjunto de datos que representa las respuestas a un cuestionario con 21 preguntas junto a un diagnostico final que dicta si la persona respondiendo el cuestionario tiene diabetes, tiene prediabetes o no tiene diabetes, por lo que la capa final de cada red neuronal utiliza softmax como activacion con 3 neuronas distintas. Fue necesario realizar ligeras transformaciones de datos para mejorar el conjunto de datos, como la aplicacion de one hot encoding y transformacion logarítmica para normalizar datos.

La red neuronal convolucional se utiliza para enfrentar el diagnostico de padecimientos detectables por fotografías de fundus retinales, utilizando un conjunto de datos que posee una serie de fotografías de fundus relacionadas a un conjunto de datos que indica si a un paciente se le puede diagnosticar una, mas de una o ninguna de 27 posibles enfermedades, mas una clase extra que agrupa distintas enfermedades con pocos ejemplos disponibles. Debido a la naturaleza y tamaño del conjunto de datos, se utilizo ImageGenerators para cargar batches de imagenes del disco para poder entrenar el modelo. Debido a que muchos de los padecimientos no se presentaban muchas veces, se decidió entrenar únicamente sobre las 7 enfermedades para los cuales existían mas de 100 ejemplos de entrenamiento, finalmente se utiliza una capa de salida de 7 neuronas con activacion sigmoidal para dar la probabilidad de padecer cada uno de los posibles padecimientos.

Finalmente, la red neuronal recurrente se utiliza para poder determinar si el texto perteneciente a un Tweet puede usarse como un indicador de que el autor padece o no de depresión. Al tratarse de texto, este fue el conjunto de datos que mas preprocesamiento tuvo, ya que fue necesario realizar tareas comunes de normalización de texto como eliminación de puntuación, convertir a lowercase, y tokenización. Al tratarse de clasificación binaria, la ultima capa de estos modelos consisten en una sola neurona con activación sigmoidal.

Para reducir tiempo de computo, se definieron distintos modelos y se entrenaron con un bajo numero de epochs, para determinar si el candidato tenia potencial o no antes de comprometer los recursos de computo a un largo tiempo de entrenamiento. Adicionalmente, la red neuronal convolucional fue entrenada utilizando un GPU K80 provisto por Google para Google Colab.

3 Resultados

3.1 Red neuronal feedforward

Los resultados distintas arquitecturas pueden observarse en la tabla 1. Debido a la similitud en los resultados, se utilizo el modelo mas simple, con una capa densa de 210 neuronas con ReLU para entrenar el modelo final, alcanzando un accuracy de 0.8630 al entrenarse durante 50 epochs.

3.2 Red neuronal convolucional

Por mucho este es el tipo de red neuronal que mas tiempo requiere de entrenamiento, por lo que la experimentación para encontrar el potencial de cada modelo consistio en realizar entrenamiento




Figure 1: Algunas activaciones convolucionales

durante una época únicamente hasta decidir que modelo podría ser mejor. Luego de este proceso se selecciono la mejor red y se entreno con un GPU con la ayuda de Google Colab. Los resultados de la etapa de experimentación se pueden ver en la tabla 2.

Curiosamente el mejor modelo fue uno sencillo con tres capas convolucionales, cada una seguida de pooling, y una sola capa densa de 128 neuronas, por lo que fue esta arquitectura la que fue sometida a entrenamiento con GPU, con resultando con un accuracy de 0.2953 y un precision de 0.3598. Algunas de las activaciones de algunos filtros se pueden ver en la figura 1

3.3 Red neuronal recurrente

Los resultados de la experimentación se pueden encontrar en la tabla 3. A pesar de que el ultimo modelo en la tabla tiene un mejor accuracy, se elige el penúltimo para realizar el entrenamiento final, esto se debe a que se buscaba un balance entre el accuracy y el precisión debido a la necesidad de realizar buenos diagnósticos. El entrenamiento final duro 20 épocas y obtuvo un accuracy de 0.9962 con una precisión de 0.9966.

4 Conclusiones

La implementación de redes neuronales tiene un gran potencial para asistir el diagnostico de algún padecimiento, aunque depende mucho del padecimiento en cuestión y la data disponible para analizar y entrenar los modelos.

Para este proyecto, la red feedforward y la red recurrente dieron resultados bastante prometedores. Por su parte, la red convolucional no rindió resultados suficientemente buenos como para asistir realmente en la toma de decisión, la causa de esto puede estar amarrada a la falta de ejemplos de entrenamiento, puesto que el conjunto entero de datos esta limitado a 3,200 imágenes en total. A pesar del pobre rendimiento de la red convolucional, no se desacredita la idea de poder apoyarse en estos modelos para asistir la toma de decisiones, solo refuerza la necesidad de obtener conjuntos de datos apropiados y/o de aplicación específica.

Table 2: Red neuronal convolucional

Capas ocultas	Red	Entrenamiento		Prueba	
	Capas	Accuracy	Precision	Accuracy	Precision
12	Conv2D, 16x3x3, ReLU BatchNormalization Pooling 2x2 Conv2D, 32x3x3, ReLU BatchNormalization Pooling 2x2 Conv2D, 64x3x3, ReLU BatchNormalization Pooling 2x2 Flatten Densa, 128, ReLU BatchNormalization	0.2250	0.1759	0.3219	0.3213
InceptionV3 + 1	Capas de InceptionV3 hasta 'mixed7' Densa, 128, ReLU	0.2094	0.1667	0.2094	0.0870
InceptionV3 + 12	Capas de InceptionV3 hasta 'mixed7' Conv2D, 16x3x3, ReLU BatchNormalization Pooling 2x2 Conv2D, 32x3x3, ReLU BatchNormalization Pooling 2x2 Conv2D, 64x3x3, ReLU BatchNormalization Pooling 2x2 Flatten Densa, 128, ReLU BatchNormalization	0.2057	0.1657	0.1219	0.0

References

References follow the acknowledgments. Use unnumbered first-level heading for the references. Any choice of citation style is acceptable as long as you are consistent. It is permissible to reduce the font size to small (9 point) when listing the references. Note that the Reference section does not count towards the page limit.

[1] Samiksha Pachade, Prasanna Porwal, Dhanshree Thulkar, Manesh Kokare, Girish Deshmukh, Vivek Sahasrabuddhe, Luca Giancardo, Gwenolé Quéllec, Fabrice Mériaudeau. (2020). Retinal Fundus Multi-disease Image Dataset (RFMiD). IEEE Dataport. <https://dx.doi.org/10.21227/s3g7-st65>

[2] Centers for Disease Control and Prevention (CDC). Behavioral Risk Factor Surveillance System Survey Data. Atlanta, Georgia: U.S. Department of Health and Human Services, Centers for Disease Control and Prevention, 2015

A Appendix

Los notebooks de experimentacion pueden encontrarse en: <https://github.com/HOCHM31573R/SL2-Proyecto>

El dataset utilizado para la red neuronal recurrente puede encontrarse en: <https://www.kaggle.com/datasets/infamouscoder/mental-health-social-media>

Table 3: Red neuronal recurrente

Capas ocultas	Red	Entrenamiento		Prueba	
	Tipo, neuronas, activación	Accuracy	Precision	Accuracy	Precision
3	Embedding, 128 Bidirectional(LSTM), 64, retorna secuencia Bidirectional(LSTM), 64	0.9533	0.9485	0.8522	0.8515
4	Embedding, 128 Bidirectional(LSTM), 64, retorna secuencia Bidirectional(LSTM), 64 Densa, 32, ReLU	0.9505	0.9454	0.8515	0.8512
6	Embedding, 128 Bidirectional(LSTM), 64, retorna secuencia Dropout, 0.2 Bidirectional(LSTM), 64 Densa, 32, ReLU Dropout, 0.2	0.9471	0.9414	0.8550	0.8560
6	Embedding, 256 Bidirectional(LSTM), 128, retorna secuencia Dropout, 0.2 Bidirectional(LSTM), 64a Densa, 64, ReLU Dropout, 0.2	0.9547	0.9509	0.8580	0.8219
6	Embedding, 256 Bidirectional(LSTM), 128, retorna secuencia Dropout, 0.2 Bidirectional(LSTM), 64 Densa, 32, ReLU Dropout, 0.2	0.9561	0.9504	0.8515	0.8805
8	Embedding, 256 Bidirectional(LSTM), 128, retorna secuencia Dropout, 0.2 Bidirectional(LSTM), 64 Dropout, 0.2 Bidirectional(LSTM), 32 Densa, 16, ReLU Dropout, 0.2	0.9391	0.9318	0.8512	0.8853
8	Embedding, 256 Bidirectional(LSTM), 128, retorna secuencia Dropout, 0.2 Bidirectional(LSTM), 64 Dropout, 0.2 Bidirectional(LSTM), 64 Densa, 128, ReLU Dropout, 0.2	0.9529	0.9452	0.8615	0.8524